



**Departamentul Automatică și Informatică Industrială**  
**Facultatea Automatică și Calculatoare**  
**Universitatea POLITEHNICA din București**



## **LUCRARE DE DIPLOMĂ**

### **Detectarea tulburărilor dermatologice prin analiza de imagini**

Coordonator

Ș.l. Dr. Ing. Muraru Mihnea

Absolvent

Vanessa-Ramona Marin

**2023**



## 1 Cuprins

1. Introducere.....	4
1.1 Context .....	4
1.2 Domeniul lucrării.....	5
2. Problematika propusă .....	7
3. Lucrări conexe .....	8
4. Principii teoretice de bază.....	11
4.1 Inteligență Artificială.....	11
4.2 Vedere Artificială .....	11
4.3 Învățarea Profundă.....	12
4.4 Învățarea prin transfer de cunoștințe .....	12
4.5 Rețele Neuronale Convoluționale.....	13
4.6 Scurtă prezentare a tehnologiilor .....	13
4.6.1 Python.....	13
4.6.2 Flask .....	13
4.6.3 React .....	14
5. Metodologie propusă .....	15
5.1 Colectarea datelor .....	15
5.1.1 Accesarea setului de date.....	15
5.1.2 Prezentarea setului de date .....	15
5.1.3 Scurtă perspectivă medicală a setului de date .....	15
5.2 Prelucrarea datelor .....	16
5.3 Stabilirea arhitecturii modelului .....	20
5.3.1 Modelul pre-antrenat .....	20
5.3.2 Modificările aduse modelului ResNet50V2 .....	21
5.4 Algoritm de antrenare.....	26
6. Rezultate .....	28
7. Interfața cu utilizatorul .....	31
7.1 Implementare .....	31
7.2 Mod de utilizare a interfeței.....	32
8. Comparatie cu abordările anterioare.....	33
9. Concluzii.....	34
10. Considerente pentru o dezvoltare viitoare .....	35
Bibliografie.....	36

# **1. Introducere**

## **1.1 Context**

Pielea este considerată a fi cel mai mare organ uman. Are rolul de a ne proteja corpul de bacterii și infecții, acționând ca o barieră față de lumea exterioară. Aceasta este alcătuită din trei straturi: epiderm, derm și hipoderm [1].

Dermatologia a avut o evoluție semnificativă de-a lungul anilor. Primele informații privind bolile de piele au apărut în scrierile egiptene, perioadă în care s-au prescris și primele tratamente. Perioada renașcentistă a adus după sine o înțelegere mai bună a bolilor pielii, prescripția tratamentelor se făcea în baza obiceiurilor și tradițiilor locale, cu o abordare naturistă. Secolul al XX-lea, datorită progresului științific și tehnologic, apar primele tratamente terapeutice, chirurgicale și proceduri de înfrumusețare. În secolele al XVIII-lea și al XIX-lea, în Europa s-au stabilit fundațiile științei de dermatologie prin intermediul teoriilor, descoperirilor și a cunoștințelor ce se folosesc și în prezent [2].

Spre exemplu, în această perioadă s-au făcut progrese semnificative în înțelegerea și descrierea unor afecțiuni specifice ale pielii, cum ar fi vitiligo, lupus eritematos, psoriazis și sifilisul cutanat. Aceste descoperiri au contribuit la dezvoltarea metodelor de diagnostic și tratament pentru aceste boli.

Așadar, modul în care pielea reacționează la factorii exteriori este un subiect ce a captat atenția oamenilor încă din antichitate. Cercetarea și progresul în dermatologie a dus la găsirea de tratamente pentru diverse boli considerate fatale în trecut, precum: lepra, ciuma bubonică și variola.

O perioadă marcantă pentru umanitate și pentru domeniu dermatologic a fost reprezentată de secolul al XIV-lea, cunoscut pentru pandemia de ciumă bubonică denumită Ciuma Neagră. Această pandemie a ucis mai mult de o treime din populația Europei. Din neregnoașterea cauzelor și tratamentelor specifice, cum ar fi antibioticele, ciuma bubonică ducea la leziuni cutanate grave, conducând ulterior la deces [3].

În secolul al XVIII-lea, în Europa, 400.000 de oameni mureau anual din cauza variolei, iar o treime dintre supraviețuitori ajungeau să orbească. Boala se manifestă la nivelul pielii prin erupții cutanate, ce se pot infecta. Edward Jenner a creat vaccinul împotriva variolei, în 14 mai 1796, care este folosit și în prezent [4].

În prezent, un număr foarte mare de afecțiuni ale pielii sunt tratabile. De asemenea, datorită conlucrării dintre medicină și tehnologie, majoritatea procedurilor ce au loc la nivelul pielii sunt neinvazive, nedureroase și eficiente.

Cele mai recente statistici realizate de Organizația Mondială a Sănătății (OMS) [5], arată că în România în anul 2019, 929 de oameni au murit din cauza cancerului de piele. Din cauza încălzirii globale și a indicelui UV ridicat, pielea este atacată de factori dăunători în mod

contant. De aceea, prevenția și consultul periodic la medicul dermatolog nu ar trebui să lipsească.

Pentru a diminua numărul de decese ca urmare a cancerului de piele, oamenii de știință au realizat numeroase lucrări pentru detectarea timpurie a acestuia folosind tehnologia, făcând posibilă identificarea unei posibile leziuni maligne cu ajutorul imaginilor.

În plus, un aspect foarte important, când vorbim de afecțiunile ce apar la nivelul pielii, este cel psihologic. Pielea este cea mai expusă parte a corpului uman. Așadar în cazul bolilor autoimune ce se manifestă prin diferite leziuni cutanate precum psoriazisul, efectele psihologice sunt inevitabile. De cele mai multe ori, acestea sunt asociate cu nivel de stres crescut, anxietate, rușine, izolare socială, scăderea stimei de sine sau chiar depresie [6].

Altfel spus, detectarea timpurie și începerea rapidă a tratamentelor duc la îmbunătățirea vieții individului, atât din punct de vedere al sănătății fizice cât și psihice.

## 1.2 Domeniul lucrării

Lucrarea este construită prin îmbinarea cunoștințelor din domeniile tehnice: Inteligență Artificială, Învățare Automată, Învățare Profundă și Vedere Artificială și a celor din domeniu medical.

Lucrarea folosește învățarea prin transfer de cunoștințe pentru a antrena o rețea neuronală convoluțională pre-antrenată pe un set mare de date (imagini cu multiple afecțiuni ale pielii), pentru rezolvarea unei alte sarcini de detecție a tulburărilor dermatologice cu ajutorul unui număr mai mic de imagini cu leziuni cutanate. Astfel, folosirea acestor informații în implementarea sa, o încadrează în domeniul Învățării Profunde.

De asemenea, aceasta face parte din domeniu Vederii Artificiale datorită nevoii de procesare și modelare a imaginilor prin aplicarea de filtre, redimensionare și normalizare, în vederea antrenării ulterioare.

Domeniile de Inteligență Artificială și Învățare Automată se reflectă în cadrul lucrării datorită algoritmilor de învățare automată folosiți pentru crearea unui sistem complex de clasificare și identificare.

Pe de altă parte, lucrarea este asociată și domeniului aplicațiilor Web, deoarece pune la dispoziție o interfață ușor de folosit și înțeles de către utilizator.

Nu în ultimul rând, pe lângă domeniile tehnice discutate mai sus, lucrarea se extinde și în zona științelor medicale prin natura problemei analizate și a soluțiilor propuse.

Rezultatele privesc informații ce se regăsesc în domeniul dermatologic, ramură a medicinei, datorită concluziilor specifice pe care le furnizează.

Prin urmare, lucrarea nu se limitează la un singur domeniu, ci explorează o arie de interes mai largă, concentrându-se pe intersecția dintre domeniul medical și științele ingineresti.

## **2. Problematica propusă**

Lucrarea urmărește să ofere o aplicație pentru identificarea cât mai corectă a unui număr de patologii dermatologice, folosind diferite tehnici de prelucrare a imaginilor și algoritmi de învățare automată. Aceasta își propune să ofere un mijloc rapid de recunoaștere a afecțiunilor de la nivelul pielii.

Detectarea rapidă și ușoară a leziunilor cutanate duce la vindecare mai rapidă a bolii, ceea ce în cele mai multe cazuri îmbunătățește viața pacientului și uneori o salvează. Importanța acestui aspect este marcată de următorii factori:

- Detectarea timpurie a cancerului de piele, crește șansele de supraviețuite a persoanelor ce prezintă leziuni maligne;
- Depistarea în stadii incipiente a bolilor autoimune, ce se manifestă la nivelul pielii, duce la începerea rapidă a tratamentului ceea ce se reflectă în îmbunătățirea calității vieții;
- Efectele psihologice care apar ca urmare a înrăutățirii leziunilor cutanate;
- Apariția diferitelor manifestări cutanate ca urmare a contractării unei boli cu transmitere sexuală, pot reprezenta un subiect sensibil, provocând amânarea consultului la un medic dermatolog, rezultând deteriorarea sănătății și transmiterea acesteia.

Modalitățile de diagnosticare sunt multiple, în schimb accesul la ele poate fi anevoios și costisitor. Așadar, algoritmi de învățare automată pot reprezenta o metodă adițională de identificare a bolilor de piele. Prin urmare, această metodă poate reprezenta o modalitate de conștientizare pentru necesitatea consultului la un medic specialist în cazul apariției unor leziuni ale pielii. Astfel, ea poate fi folosită ca un semnal de alarmă pentru cei care sunt timizi în a consulta un medic specialist în astfel de situații.

### 3. Lucrări conexe

În prezent, există o serie de lucrări științifice pe tema detecției de leziuni cutanate, utilizând numeroase metode de clasificare și diverși algoritmi de învățare automată.

O lucrare care a urmărit clasificarea afecțiunilor pielii folosind concepte de Învățare Profundă este: “Detection and classification of skin diseases with ensembles of deep learning networks in medical imaging”, Kalaivani, A., & Karpagavalli, S. Această lucrare propune identificarea a șapte categorii a tulburărilor dermatologice, plecând de la setul de date HAM10000. Sunt folosiți algoritmi precum Random Forest pentru o mai bună clasificare a datelor [7].

În plus, lucrarea dorește compararea rezultatelor obținute în urma folosirii a două arhitecturi de rețele neuronale: un model clasic de rețea neuronală convoluțională și un model de rețea neurală convoluțională profundă. Se folosește tehnica Random Forest pentru a îmbunătăți performanța modelului.




Figura 1. Captură cu graficul rezultatelor obținute, conform [7]

Astfel, lucrarea analizează o serie de metrici pentru a măsura performanța obținută cu cele două arhitecturi de rețele neuronale folosite. Metricii folosiți sunt: precizia, procentul de date identificate corect, măsura F (media armonică între procentul de date identificate corect și precizie) și acuratețea.



Tabel 1. Tabel cu rezultatele numerice obținute pentru fiecare arhitectură folosită, conform [7]

Percentage of performance for various metrics	Classical CNN based Model	RF-DCNN Classifier model
Precision %	88	95.41
Recall %	89	94.93
F-measure %	89	95.17
Accuracy %	88	96.1

O altă lucrare este “Skin Lesion analysis towards Melanoma Detection Using Deep Learning Network”, Yuexiang Li and Linlin Shen [8].

Această lucrare se axează pe recunoașterea melanomului în vederea detectării timpurii a cancerului de piele. Datele de intrare folosite sunt cele propuse în ISIC (International Skin Imaging Collaboration) 2017.

Primii pași prezentați în această lucrare explică metoda de procesare a imaginilor astfel încât setul de date să poată fi utilizat în procesul de învățare. Imaginile sunt redimensionate în funcție de zona cu piele afectată a acestora. Patologia este poziționată central în cadrul datelor de intrare digitale. Această metodă de prelucrare are ca scop păstrarea leziunilor intacte și minimizarea conținutului neutru din imagini. Setul de date cuprinde imagini cu trei categorii de leziuni: melanom, keratoză seboreică și nevi. Deoarece numărul imaginilor pentru fiecare categorie nu era identic, s-au folosit metode de augmentare a datelor pentru a obține un set de date uniform.

Arhitectura rețelei neuronale folosite este FCRN-88 (Fully Convolutional Residual Network), pe baza căreia se construiește o rețea de indexare a leziunilor. Exemplificarea modului de funcționare este dată de utilizarea a două FCRN-uri antrenate folosind diferite metode de augmentare cu scopul de a îmbunătăți rezultate pentru cele trei categorii: melanom, keratoză seboreică și nevi.

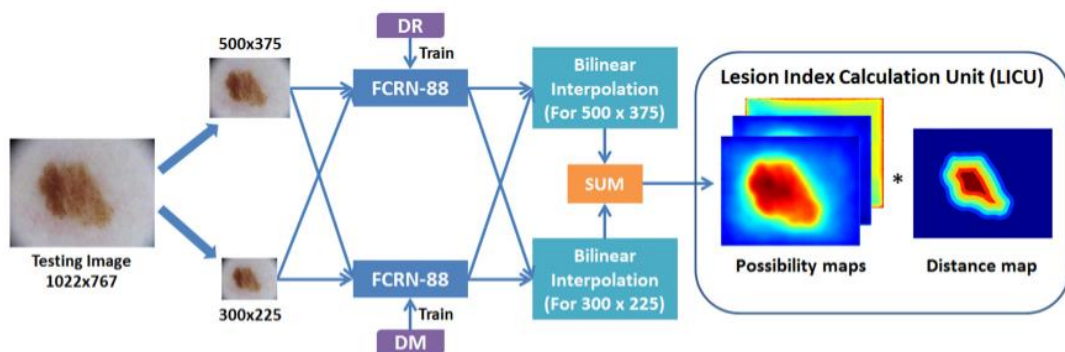


Figura 2. Schema rețelei de indexare a leziunilor folosind două FCRN-uri, conform [8]

De asemenea, lucrarea introduce ideea de Unitate de Calcul a Indicelui de Leziuni (LICU) pentru a rafina rezultatele obținute de la cele două FCRN-uri.

Rezultatele obținute sunt comparate cu cele furnizate de alte cinci arhitecturi de rețele neuronale: AlexNet, VGG-16, ResNet-50, ResNet-101 și Inception-v3.

Tabel 2. Performanțele obținute în urma clasificării leziunilor cutanate folosind diferite rețele neuronale, preluat din [8]

Method	JA	AC	DC	SE	SP
FCN-8s	0.696	0.933	0.783	0.806	0.954
U-net	0.651	0.920	0.768	0.853	0.957
II-FCN	0.699	0.929	0.794	0.841	0.984
Auto-ED	0.738	0.936	0.824	0.836	0.966
LIN	0.753	0.950	0.839	0.855	0.974

În cele din urmă, lucrarea oferă o soluție pentru procesarea, segmentarea, extragerea și clasificarea patologiei dermatologice folosind o rețea de indexare a leziunilor. De asemenea, aceasta introduce noțiunea de unitate de calcul a indicelui de leziuni pentru determinarea importanței fiecărui pixel în procesul de clasificare [8].

## 4. Principii teoretice de bază

### 4.1 Inteligență Artificială

Unul dintre pionierii domeniului de Inteligență Artificială, John McCarthy, a descris procesul în anul 1955 ca fiind: „Crearea de mașini inteligente care pot efectua sarcini care, în mod tipic, necesită inteligență umană, cum ar fi percepția, raționamentul și luarea deciziilor.” [9].

Prin urmare, domeniul Inteligenței Artificiale se ocupă cu realizarea de sisteme inteligente, care se doresc să efectueze diferite operațiuni care ar trebui făcute, în mod uzual, de către oameni. De asemenea, această ramură a științei calculatoarelor este complexă. Astfel, dezvoltarea de aplicații care să se regăsească în această arie a tehnologiei trebuie să treacă prin numeroase etape de testare pentru a le fi validat comportamentul corect și așteptat. De aceea, datele cu care se lucrează trebuie să fie clare.




Figura 3. Imagine portretizând domeniul Inteligenței Artificiale și din ce este alcătuit [10]

Acest domeniu se regăsește în diferite industrii: transporturi, medicină, comerț, finanțe și educație. Așadar, Inteligența Artificială a dus la îmbunătățirea vieții oamenilor, ocupându-se de procesele periculoase, repetitive și complicate în locul acestora [11].

### 4.2 Vedere Artificială

Vederea Artificială aduce la un loc toate metodele de procesare și prelucrare a imaginilor și/sau datelor video. Mecanismele folosite în cadrul acestui domeniu sunt: detecția, segmentarea, etichetarea și recunoașterea obiectelor sau a caracteristicilor specifice.

De asemenea, în cazul aplicațiilor ce se ocupă de analiza imaginilor, multe dintre procedurile de prelucrare a datelor presupun redimensionarea acestora, normalizarea pixelilor și aplicarea de filtre.

Astfel, redimensionarea se ocupă de modificarea dimensiunilor matricei ce definește imaginea. Spre exemplu, pentru a obține o dimensiune de 150x150 (pixeli) dintr-o imagine de dimensiune 240x180 (pixeli) se aplică redimensionarea pe reprezentarea grafică inițială.

În plus, procesul de normare a pixelilor are ca scop reducerea intensității acestora ceea ce asigură păstrarea trăsăturilor esențiale din imagine și claritatea acesteia. De asemenea, pentru a efectua operații complexe (conversii, detecția caracteristicilor specifice și/sau minimizarea zgomotului), se folosesc filtre. Aceste filtre sunt reprezentate printr-o matrice de dimensiuni mici, ce funcționează ca o mască pentru imaginea originală.




Figura 4. Diagramă privind prelucrarea imaginilor pentru clasificare

În final, Vederea Artificială se regăsește în viața cotidiană a oamenilor prin aplicații de recunoaștere facială, detectare a obstacolelor și obiectelor și securizare a bunurilor sau locuinței.

### 4.3 Învățarea Profundă

Învățarea Profundă le oferă calculatoarelor posibilitatea de a construi soluții complexe folosind concepte simple [12].

Componenta principală a Învățării Profunde este reprezentată de rețelele neuronale, care sunt construite din mai multe straturi (convoluționale, de agregare, de normalizare etc.) ce oferă modelului posibilitatea de a învăța automat trăsăturile importante ale datelor de intrare.

Performanțele obținute datorită algoritmilor de Învățare Profundă au dus la îmbunătățirea proceselor ce se ocupă cu manipularea și identificarea imaginilor. Tehnologiile care au la bază aceste principii sunt foarte ușor de recunoscut în viața de zi cu zi, oferind soluții de securitate a datelor, detectare a obiectelor și automatizare a proceselor industriale ce se pot realiza cu ajutorul imaginilor.

### 4.4 Învățarea prin transfer de cunoștințe

Învățarea prin transfer de cunoștințe (*transfer learning*) îmbunătățește învățarea prin formarea de conexiuni între sarcinile realizate anterior și sarcina curentă, furnizând o soluție mai bună și mai rapidă [13].

Principiul de funcționare se bazează pe realizarea a trei acțiuni definitorii:

1. Selectarea unui model care a fost deja antrenat pe un set de date de dimensiune mare;
2. Înghețarea primelor straturi ale modelului;

3. Adăugarea unor straturi noi care să definească noile caracteristici ale modelului pre-antrenat pentru a realiza noua sarcină.

În final, Învățarea prin Transfer de Cunoștințe este o metodă folosită la scară largă pentru realizarea rapidă a aplicațiilor de Învățare Automată cu rezultate bune de identificare, recunoaștere și detecție fără a fi nevoie de un set de date mare.

## 4.5 Rețele Neuronale Convoluționale

Rețelele Neuronale Convoluționale au o arhitectură structurată pe straturi, fiecare având un număr de neuroni.

În componența Rețelor Neuronale Convoluționale avem trei straturi foarte importante:

- Straturi de convoluție – care se ocupă de extragerea caracteristicilor printr-o combinație de operații liniare și nonliniare (convoluție și funcția de activare) [14].
- Straturi de agregare – reduc hărțile de caracteristici pentru ca rețeaua să nu fie afectată foarte mult de schimbările de poziție sau formă, și pentru a restrânge parametrii pe care aceasta trebuie să-i învețe [14].
- Straturile complet conectate – se regăsesc după straturile de convoluție și agregare, conectând datele de intrare cu datele de ieșire ale rețelei cu ajutorul unor greutateți ajustabile [14].

Pentru realizarea aplicațiilor din domeniu medical, rețelele convoluționale sunt instrumentul principal pentru efectuarea proceselor de clasificare și detecție a diferitelor afecțiuni de sănătate folosind date digitale sau numerice.

## 4.6 Scurtă prezentare a tehnologiilor

### 4.6.1 Python

Python este un limbaj de programare care pune la dispoziție diferite paradigme de programare precum: procedurală, imperativă, funcțională și orientată pe obiect. Datorită flexibilității de paradigmă a acestui limbaj, Python se poate folosi în dezvoltarea de aplicații cu scopuri de utilizare diverse (web, scripting etc). Limbajul este foarte întâlnit în dezvoltarea de aplicații și proiecte care au la bază învățarea automată, deoarece compilarea nu are loc, ceea ce duce la generarea și afișarea rapidă a rezultatelor.

### 4.6.2 Flask

Flask este un cadru web utilizat la aplicațiile web de dimensiuni mici. Acesta este ușor de utilizat și oferă metode de realizare și gestionarea a cererilor HTTP (Hypertext Transfer Protocol) [15].

### 4.6.3 React

React este o bibliotecă folosită pentru dezvoltarea de interfețe cu ajutorul căreia utilizatorul să interacționeze cu aplicația [16].

Mai mult, React este o librărie din cadrul limbajului de programare JavaScript care permite realizarea de aplicații capabile să se adapteze la diferite dimensiuni ale ecranului. React oferă posibilitatea de integrare acestuia cu alte librării. Astfel, arhitectura aplicației nu este restricționată, modelarea acesteia în timpul dezvoltării nefiind un impediment.

## **5. Metodologie propusă**

### **5.1 Colectarea datelor**

#### **5.1.1 Accesarea setului de date**

Pentru colectarea datelor, este nevoie să se urmeze pașii:

- Accesarea paginii HARVARD Dataverse.
- Acceptarea Termenilor și Condițiilor conform cărora setul de date “HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions” este folosit în scop non-comercial [17].

#### **5.1.2 Prezentarea setului de date**

Setul de date “HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions” conține un număr de 10.015 imagini dermatoscopice împărțite în șapte categorii de leziuni:

1. Carcinom intraepitelial și keratoză actinică / boala Bowen
2. Carcinom bazocelular
3. Leziuni benigne asemănătoare keratozei (pete lentigo solare / keratoze saboreice și keratoze asemănătoare mușcăturilor)
4. Dermatofibrom
5. Melanom
6. Nevi melanocitari
7. Leziuni vasculare (angioma, angiokeratoame, granuloame piogene și hemoragie) [17].

#### **5.1.3 Scurtă perspectivă medicală a setului de date**

**Kerotoza actinică** – apare predominant la persoanele care au fost expuse la soare pe perioade de timp lungi și repetate. Aceasta se manifestă sub forma unor pete roșii, aspre și neregulate. Zonele cele mai afectate sunt fața, scalpul și partea expusă a membrelor superioare [18].

**Carcinomul intraepitelial** – reprezintă celule cancerigene localizate în epiderm. În literatura de specialitate e cunoscut drept boala Bowen. De asemenea, una din cauzele apariției acestui carcinom este dată de expunerea îndelungată la soare. Acesta se manifestă prin apariția unor pete roșii și aspre pe suprafața pielii. În plus, e cunoscut faptul că dacă nu este detectat în faze incipiente, ceea ce înseamnă că acesta se dezvoltă până când apare cancerul de piele [19].

**Carcinomul bazocelular** – este cauza celui mai comun cancer de piele. Acesta se dezvoltă lent, ceea ce duce la apariția rară a metastazelor [20].

**Leziuni benigne asemănătoare keratozei (pete lentigo solare / kerotoze saboreice și keratoze asemănătoare mușcăturilor)** – sunt leziuni pigmentate, benigne des întâlnite. Datorită trăsăturilor specifice pe care aceste forme de leziuni benigne le au, sunt foarte ușor de identificat [21].

**Dermatofibrom** – este o leziune cutanată ce se găsește frecvent în dermul pielii. Se identifică ca noduli de dimensiuni foarte mici pe suprafața pielii, cel mai des prezentându-se pe extremități [22].

**Melanomul** – este o formă foarte gravă de cancer de piele și are trăsături foarte bine definite. Acesta își schimbă culoarea, dimensiunea și forma în timp. De obicei, nu se prezintă ca fiind o leziune uniformă, ci foarte neregulată [23].

**Nevi melanocitari** – pot apărea peste tot pe suprafața corpului. Sunt alunițe, în general, de natură benignă, foarte rar ajungând să devină melanoame. De obicei, au o culoare uniformă, de dimensiuni mici, rotunde și simetrice. Numărul lor crește odată cu înaintea în vârstă a individului [24].

**Leziuni vasculare (angioma, angiokeratoame, granuloame piogene și hemoragie)** – sunt leziuni benigne cu o culoare specifică, care variază între un roz deschis și un violet închis [25].

## 5.2 Prelucrarea datelor

Setul de date folosit este împărțit în șapte clase diferite, fiecare clasă are asociată o tulburare dermatologică. Fiecare imagine are o etichetă care definește clasa din care face parte leziunea cutanată. Etichetele folosite sunt:

1. **nv** - Nevi melanocitari
2. **mel** - Melanom
3. **bk1** - Leziuni benigne asemănătoare keratozei (pete lentigo solare / kerotoze saboreice și keratoze asemănătoare mușcăturilor)
4. **bcc** - Carcinom bazocelular
5. **akiec** - Carcinom intraepitelial și kerotoză actinică / boala Bowen
6. **vasc** - Leziuni vasculare (angioma, angiokeratoame, granuloame piogene și hemoragie)
7. **df** - Dermatofibrom






Figura 5. Împărțirea inițială a setului de date în funcție de cele șapte clase

Algoritmii de Învățare Automată lucrează cu valori numerice, iar setul de date are atribuite etichete alfabetice. Așadar, numele claselor folosite pentru definirea tulburărilor dermatologice sunt transformate în valori numerice.

Inițial setul de date este unul nebalansat, fiecare boală având un număr diferit de imagini. Diferența semnificativă dintre clase poate favoriza procesul de învățare al modelului în cazul claselor cu un mare de date (nevi melanocitari), spre deosebire de celelalte, ceea ce poate conduce la obținerea unor performanțe reduse.

Pentru a rezolva problema setului de date nebalansat s-au folosit tehnici de supradimensionare și subdimensionare pentru a obține un număr de imagini uniform pe toate clasele. Procesele de supradimensionare și subdimensionare se realizează folosind metoda matematică numită interpolare biliniară. Această metodă presupune calcularea mediei ponderate a vecinilor cei mai apropiați ai fiecărui pixel din imaginea originală. Rezultatul obținut în urma aplicării mediei ponderate reprezintă valorile pixelului din imaginea de ieșire, redimensionată. Astfel, s-a ales o valoare standard, care să definească numărul de imagini pe care fiecare clasă să-l aibă. Pentru clasele cu un număr mic de date s-a făcut supradimensionare setul prin generarea de noi imagini, iar pentru cele cu un număr mare s-a făcut subdimensionare, lucru ce a permis reducerea setului la valoarea standard, imaginile rămase au fost aleator alese.




Figura 6. Grafic ilustrând setul de date balansat și etichetat numeric

Pentru a prelucra ulterior datele, fiecărei imagini  $i$  se asociază calea către zona unde aceasta este stocată. Setul de date cu imagini este amestecat pentru a asigura o bună adaptare a modelului la furnizarea de date noi, nemaivăzute.

Imaginile au fost redimensionate astfel încât dimensiunile lor să fie: lungimea de 100 pixeli și lățimea de 75 de pixeli. Redimensionarea s-a realizat aplicând un algoritm de interpolare biliniară.

Interpolarea biliniară este definită ca o interpolare liniară pe două direcții sau axe [26].

Algoritmul interpolării biliniare:




Figura 7. Imagine ce ajută la demonstrarea teoretică [26]

Se aleg 4 pixeli  $Q_{11}(x_1, y_1)$ ,  $Q_{12}(x_1, y_2)$ ,  $Q_{21}(x_2, y_1)$ ,  $Q_{22}(x_2, y_2)$ . Se determină coordonatele celor doi pixeli intermediari  $R_1(x, y)$ ,  $R_2(x, y)$ , cu ajutorul cărora se află coordonatele pixelului nostru  $P(x, y)$ :

- Se realizează doua interpolări liniare pe axa Ox pentru  $R_1$  și  $R_2$ : (1)

$$R_1(x, y) = Q_{11} \times \frac{x_2 - x}{x_2 - x_1} + Q_{21} \times \frac{x - x_1}{x_2 - x_1}$$

$$R_2(x, y) = Q_{12} \times \frac{x_2 - x}{x_2 - x_1} + Q_{22} \times \frac{x - x_1}{x_2 - x_1} \quad (2)$$

- Se realizează o interpolare liniară pe axa Oy pentru  $P(x, y)$ :

$$P(x, y) = R_1 \times \frac{y_2 - y}{y_2 - y_1} + R_2 \times \frac{y - y_1}{y_2 - y_1} \quad (3)$$

După redimensionare, pixelii imaginilor sunt normalizați. Valorile pixelilor care sunt inițial cuprinse între  $[0, 255]$  sunt scalate la  $[0, 1]$ , folosind formula prezentată în [27]:

$$valoare_{normalizat\grave{a}} = \frac{(valoare_{pixelului} - valoare_{minim\grave{a}})}{valoare_{maxim\grave{a}} - valoare_{minim\grave{a}}}, \quad (4)$$

unde

$$valoare_{minim\grave{a}} = 0 \quad (5)$$

$$valoare_{maxim\grave{a}} = 255 \quad (6)$$

În final, setul de date este împărțit în date de antrenare și date de test. Primul set este folosit pentru a antrena modelul să recunoască atribute și să le învețe pentru a realiza identificarea corectă al datelor necunoscute. Cel de-al doilea set, de test, se asigură că modelul poate avea performanțe bune, nu doar pentru imaginile cu care a fost antrenat, dar și pe cele noi.




Figura 8. Grafic ce ilustrează distribuția datelor de antrenament și testare

### 5.3 Stabilirea arhitecturii modelului

Lucrarea implementează un algoritm de detecție utilizând conceptul de Învățare prin transfer de cunoștințe datorită numărului mic de date de intrare folosite și a resurselor de procesare limitate. Pentru realizarea rapidă a antrenării și a evaluării s-a folosit procesarea pe resursele GPU (Unitatea de procesare grafică).

#### 5.3.1 Modelul pre-antrenat

Modelul folosit pentru a realiza recunoașterea tulburărilor dermatologice este Resnet50V2. Această rețea reziduală face parte din familia ResNet, având în arhitectura sa 50 de straturi de neuroni.

Ideea din spatele rețelei ResNet constă în rezolvarea problemei determinate de scăderea performanțelor atunci când structura modelului are foarte multe niveluri de profunzime [28].

ResNet, pentru a adresa această problemă, utilizează blocuri reziduale, ce permit învățarea prin compararea intrării cu ieșirea dorită, în vederea aproximării rezultatului final.




Figura 9. Schema de funcționare a unui bloc residual, preluată de pe [29]

Matematic, blocul residual este exprimat folosind următoarea ecuație:

$$H(x) = F(x) + x \quad (7)$$

Astfel spus,  $H(x)$  reprezintă ieșirea dorită care se poate calcula ca suma dintre funcția învățată  $F(x)$  și intrarea blocului residual  $x$  [29].

Varianta ResNet50V2 a obținut rezultate foarte bune pe setul de date ImageNet [30], datorită arhitecturii sale complexe și a modificărilor aduse la nivelul conexiunilor dintre blocuri și propagării acestora [31].

### 5.3.2 Modificările aduse modelului ResNet50V2

Straturile rețelei pre-antrenate ResNet50V2 sunt înghețate. Astfel, antrenarea va avea loc doar la nivelul straturilor nou adăugate, reducând considerabil timpul de execuție.

În total, s-au adăugat 12 straturi noi:

- 3 straturi convoluționale
- 3 straturi de agregare
- 1 strat de aplatizare
- 3 straturi dense
- 2 straturi de normalizare

**Straturile de convoluție** – sunt folosite pentru recunoașterea trăsăturilor specifice din imagini. Acestea aplică imaginilor un filtru prin înmulțirea matricei imaginii originale cu o mască de dimensiuni mai mici. Matricea rezultată are o dimensiune redusă față de cea inițială și definește o hartă de caracteristici.

Formularea matematică este dată de [12]:

$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(m, n) K(i - m, j - n) \quad (8)$$

sau

$$S(i, j) = (K * I)(i, j) = \sum_m \sum_n I(i - m, j - n) K(m, n) \quad (9)$$

**Straturile de agregare** – se asigură că hărțile caracteristicilor furnizate de straturile convoluționale nu-și schimbă comportamentul atunci când imaginea este modificată (învârtită, redimensionată). Acest lucru se realizează prin aplicarea unui filtru care constă în determinarea valorii maxime de pe zona acoperită de acest filtru.

Formula matematică pentru această operație este prezentată în [32]:

$$f_{max}(A) = \max_{n \times m}(A_{n \times m}), \quad (10)$$

unde A reprezintă matricea filtrului aplicată asupra imaginii

**Stratul de aplatizare** – este folosit înaintea straturilor dense pentru a transforma matricea de intrare într-un vector la ieșire.

**Straturile dense** – preiau vectorii de la stratul de aplatizare și determină cărei etichete îi corespunde fiecare imagine.

**Straturile de normalizare** – se folosesc de ieșirea straturilor anterioare (convoluționale sau dense) pe care le normalizează folosind metode precum scalare și decalare. Acestea asigură o antrenare mai rapidă și o precizie mai bună [33].

De asemenea, pentru straturile convoluționale și dense se completează numărul de pixeli prin adăugarea unor margini ce au toate valorile egale cu 0 pentru ca dimensiunile imaginii să fie constante după aplicarea operațiilor corespunzătoare.

Ultimul strat al rețelei neuronale este un strat dens cu un număr de neuroni egal cu numărul de clase folosite pentru clasificare și folosește o funcție de activare softmax. Funcția de activare softmax este folosită în problemele de clasificare cu mai multe clase. Formularea matematică a aceste funcții este redată în [34]:

$$\sigma(x)_j = \frac{e^{x_j}}{\sum_{k=1}^K e^{x_k}}, \quad j = 1, \dots, K \quad (11)$$

**Funcția de activare** folosită de straturile convoluționale, de agregare și dense este funcția de activare gaussiană (GELU).

Funcția de activare gaussiană se poate exprima folosind formula matematică definită în [35]:

$$GELU(x) = xP(X \leq x) = x \Phi(x) = x \cdot \frac{1}{2} \left[ 1 + \operatorname{erf}\left(\frac{x}{\sqrt{2}}\right) \right], \quad (11)$$

unde

$$\Phi(x) = P(X \leq x), \quad X \sim \mathcal{N}(0,1) \quad (12)$$

și

$$\operatorname{erf}\left(\frac{x}{\sqrt{2}}\right) = \frac{x}{\sqrt{2}} \int_0^{\frac{x}{\sqrt{2}}} e^{-t^2} dt \quad (13)$$

x reprezintă intrarea neuronului

$\Phi(x)$  reprezintă funcția de distribuție cumulativă a distribuției normale standard.

Această funcție este aproximată cu:

$$0.5x \left( 1 + \tanh \left[ \sqrt{\frac{2}{\pi}} (x + 0.044714x^3) \right] \right) \quad (14)$$

sau

$$x\sigma(1.702x) \quad (15)$$




Figura 10. Reprezentarea grafică a funcției de activare gaussiană, funcția de activare unitate liniară rectificată și funcția de activare unitate liniară exponențială, preluată din [35]

Pentru a măsura performanțele modelului s-au folosit: funcția de pierdere de entropie încrucișată binar și acuratețea ca metrică de precizie. Acuratețea verifică cât de des modelul prezice clasa corectă pentru imaginea furnizată, iar funcția de pierdere măsoară eroarea dintre predicția modelului și valoarea reală.

O formulare matematică a acesteia este dată în [36]:

Formula generală pentru funcția de pierdere de entropie încrucișată

$$\mathcal{L}_{CE}(y, g(x, \theta)) = - \sum_{j=1}^N y_j \log(g(x_j, \theta)), \quad (16)$$

unde

$$g(x_j, \theta), \quad j = 1, \dots, N \quad (17)$$

reprezintă eticheta prezisă  $g(x_j, \theta)$  pentru obiectul  $x_j$ ,  $\theta$  reprezintă vectorul de parametri ai modelului și  $y_j$  reprezintă eticheta reală a lui  $x_j$ .

Pentru cazul particular de entropie binară, formula devine:

$$\mathcal{L}_{CE}(y, g(x, \theta)) = -y_1 \log(g(x_1, \theta)) - (1 - y_1) \log(1 - g(x_1, \theta)) \quad (18)$$

În final, arhitectura modelului după aplicarea conceptelor de Învățare prin transfer de cunoștințe devine:



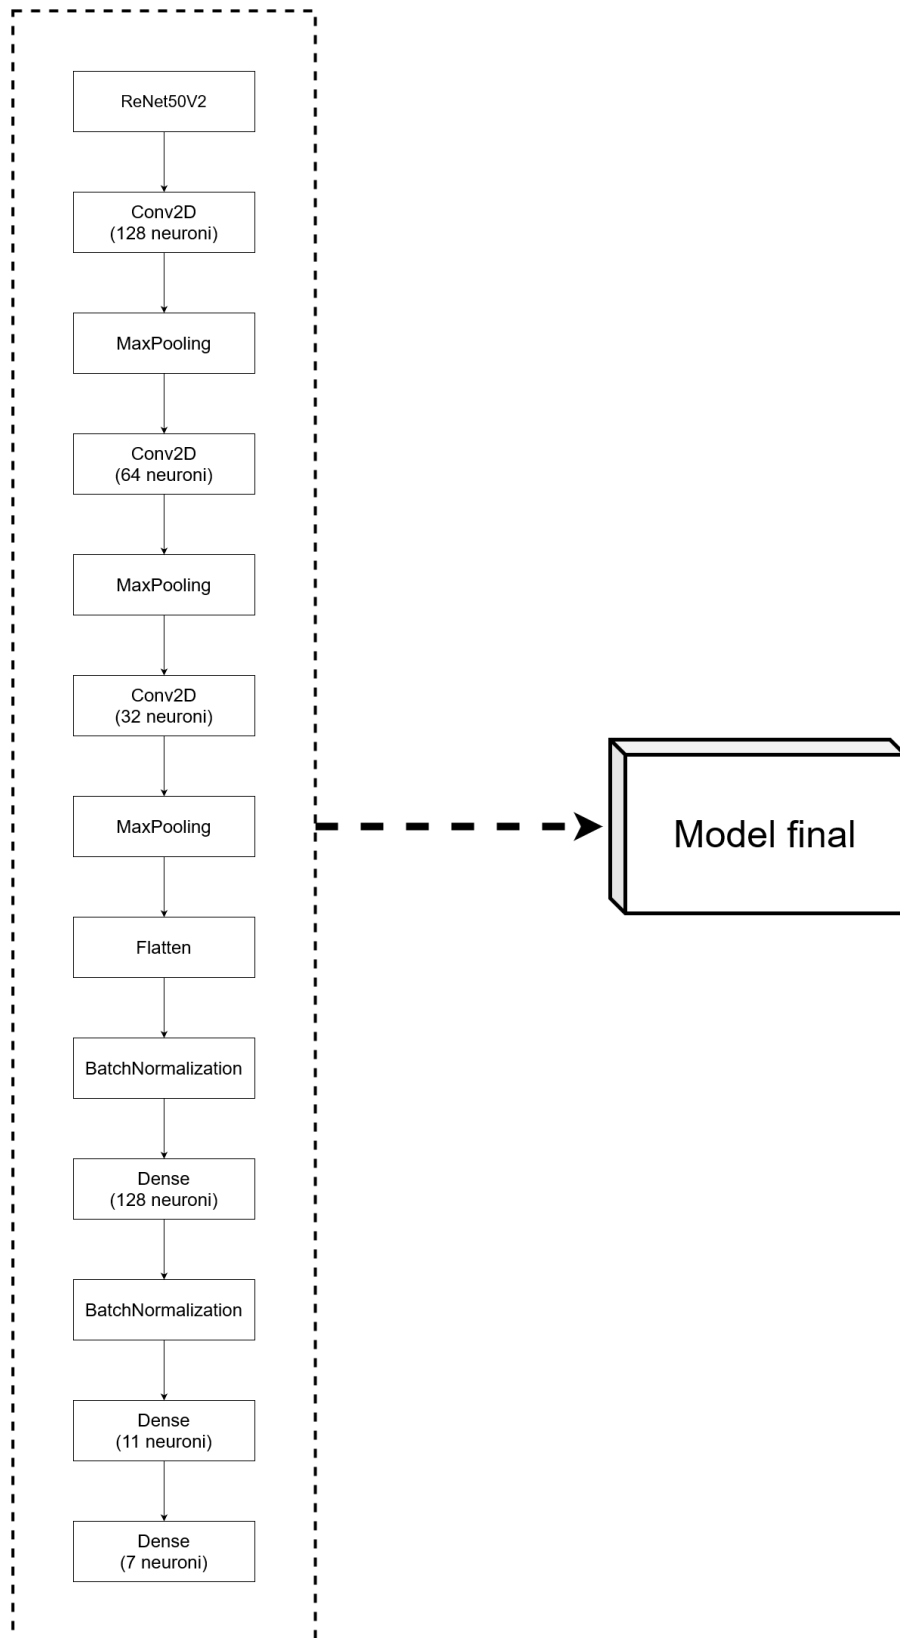


Figura 11. Arhitectura modelului final

## 5.4 Algoritmul de antrenare

Metoda de optimizare folosită pentru antrenare este RMSprop, care se poate asemăna cu algoritmul de gradient descent, adăugând conceptul de momentum pentru a eficientiza procesul de antrenare. Această metodă modifică rata de învățare ținând cont de media pătratelor gradientilor anteriori [37].

Pentru a minimiza eroarea, s-a realizat actualizarea bazată pe calculul gradientului aplicat funcției de pierdere folosind metoda de optimizare prezentată mai sus. De asemenea, pierderea este calculată realizând diferența dintre predicțiile generate de model și etichetele reale.

Ideea matematică a gradientului este foarte bine enunțată în [38]:

Problema simplificată pentru demonstrația matematică presupune ca  $x$  să fie un vector și  $L(x)$  funcția care se dorește a fi minimizată.

Ideea principală constă în modificarea lui „ $x$ ” astfel încât  $L(x)$  să descrească. Pentru a realiza acest lucru, se introduce un „ $u$ ” care referă vectorul unitate sau direcția în care  $x$  ar trebui să fie optimizat, iar „ $\alpha$ ” reprezintă scalarul acestui pas. Astfel, cu cât valoarea lui „ $\alpha$ ” e mai mare, cu atât pasul în direcția „ $u$ ” va fi mai mare. Valorile lui „ $u$ ” sunt diferite în funcție de „ $x$ ”.

Se caută un  $u$  astfel încât: (19)

$$\lim_{\alpha \rightarrow 0} L(x + \alpha u)$$

să fie minimă.

$$\lim_{\alpha \rightarrow 0} L(x + \alpha u) = u^T \nabla_x L(x) \quad (20)$$

Deci, se dorește un  $u$  astfel încât valoarea formulei:

$$u^T \nabla_x L(x) \quad (21)$$

să fie minimă.

$$\nabla_x L(x) \quad (22)$$

reprezintă gradientul funcției  $L(x)$ .

Dat fiind faptul că  $u^T$  și  $\nabla_x L(x)$  sunt vectori, putem rescrie formula ca:

$$u^T \nabla_x L(x) = |u| \cdot |\nabla_x L(x)| \cos \theta, \quad (23)$$

unde  $\theta$  este unghiul dintre cei doi vectori. Valoarea lui  $\cos\theta$  este minimizată la  $\theta = \pi$ , astfel vectorii vor avea direcții opuse.

Astfel direcția  $u$  se poate scrie ca:

$$u = -\nabla_x L(x) \quad (24)$$

Pentru mai multe valori a lui  $x$ , această demonstrație va conduce la forma iterativă:

$$x = x - \alpha \nabla_x L(x), \quad (25)$$

unde  $\alpha$  definește rata de învățare.

Astfel, în algoritmul de antrenare se realizează un Batch Gradient pe funcția de pierdere, pentru a minimiza valoarea acesteia, după formula prezentată anterior. Apoi, optimizatorul RMSprop aplică actualizarea parametrilor realizată cu ajutorul gradientului.

Antrenarea modelului este realizată printr-un număr total de 10.000 de iterații, pentru fiecare iterație calculându-se valoarea funcției de pierdere și acuratețea. De asemenea, pentru a obține cea mai bună versiune a modelului creat s-au selectat diferite valori pentru hiperparametri, aceștia fiind dimensiunea lotului de imagini care intră într-o iterație și rata de învățare.

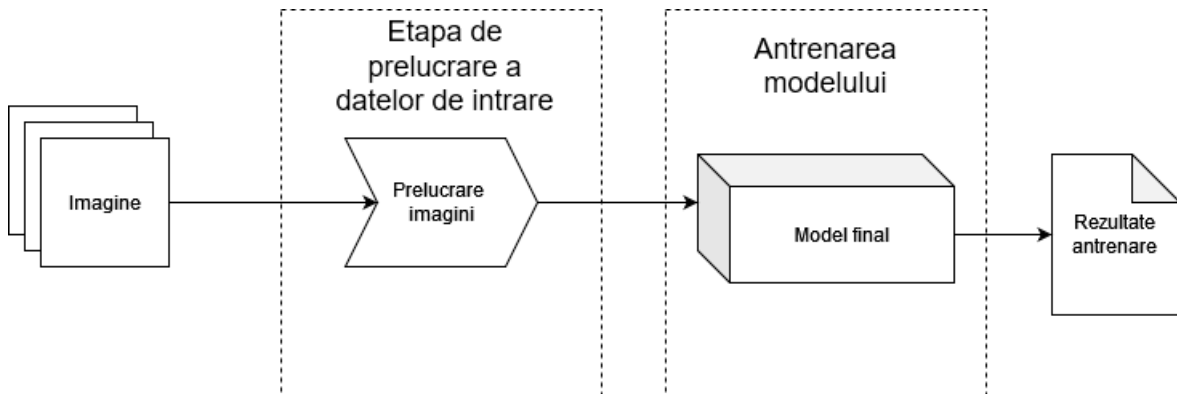


Figura 12. Schema antrenării modelului

## 6. Rezultate

Lucrarea folosește setul de date de test pentru a evalua comportamentul modelului antrenat la introducerea de imagini noi, nemaivăzute. Astfel s-au realizat evaluări pe diferite versiuni ale modelului prin schimbarea de hiperparametrilor.

Tabel 3. Rezultate obținute cu diferiți hiperparametri

Rata de învățare	Dimensiunea lotului	Pierdere	Acuratețea
0.005	32	1.3002	91.56%
0.005	64	1.3448	91.34%
0.002	32	1.2830	91.70%
0.002	64	1.2506	91.92%
0.001	32	1.2308	91.96%
0.001	64	1.1538	92.48%

În final, s-a ales versiunea modelului care a obținut o acuratețe de: 92.48% pentru evaluarea în detaliu a performanței acestuia.

Graficele pentru funcția de pierdere și acuratețe prezintă comportamentul modelului în timpul antrenării. Acestea țin cont de rezultatele plasate pe grafic la fiecare iterație pentru datele de antrenament și la cele de validare reprezentate grafic la fiecare 100 de iterații.




Figura 13. Grafice pentru reprezentarea performanțelor folosind datele de antrenament

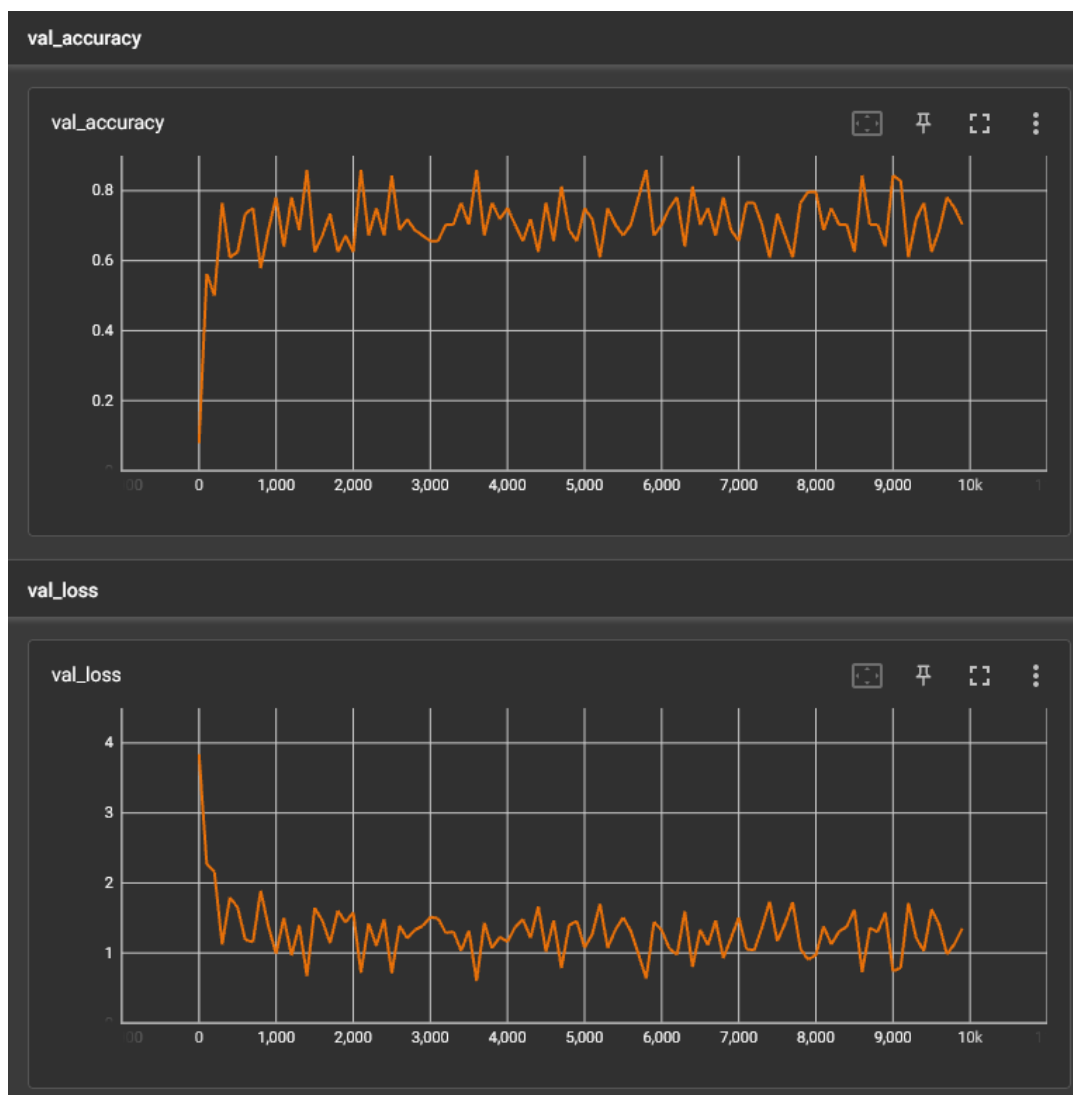


Figura 14. Graficele performanțelor folosind datele de validare la fiecare 100 de iterații

De asemenea, graficele evidențiază faptul că modelul nu prezintă fenomenele de învățare: supraînvățare sau subînvățare. Altfel spus, modelul generalizează bine atât pe setul de validare cât și pe cel de antrenare.

Un alt indicator pentru performanțele modelului este reprezentat de matricea de confuzie. Aceasta prezintă faptul că modelul clasifică tulburările dermatologice cu succes. Liniile matricei reprezintă valorile adevărate, iar coloanele reprezintă valorile prezise. Diagonala principală prezintă numărul de clasificări corecte, iar valorile din triunghiurile adiacente acestuia prezintă cazurile clasificărilor greșite.

Mai mult, modelul determină foarte bine tulburările precum: dermatofibromul, nevii melanocitari și carcinomul intraepitelial și keratoza actinică / boala Bowen. Afecțiunile cel mai greu de detectat de către model sunt leziunile benigne asemănătoare keratozei (pete lentigo solare / keratoze saboreice și keratoze asemănătoare mușcăturilor).




Figura 15. Imagine cu matricea de confuzie

Deoarece liniile matricei sunt valorile adevărate, iar coloanele cele prezise, matricea de confuzie se interpretează astfel:

Pentru primul element de pe diagonala principală a matricei  $CM(1,1)$  valoarea adevărată este akiec, iar cea prezisă tot akiec.

Pentru elementul  $CM(2,5)$  din triunghiurile adiacente diagonalei principale, valoarea de adevărată este bcc, iar cea prezisă mel.

## **7. Interfața cu utilizatorul**

Interfața cu utilizatorul a fost realizată astfel încât să fie foarte ușor de folosit. Această constă în două pagini principale. Prima pagină este destinată încărcării imaginii de către utilizator în vederea detecției tulburări dermatologice. Tot în pagina principală se găsește și o căsuță de bifat în vederea acceptării utilizării informațiilor cu caracter personal. Odată bifată, utilizatorul va putea încărca imaginea. Cea de-a doua pagină se ocupă de afișarea rezultatelor finale după procesare.

### **7.1 Implementare**

Interfața cu utilizatorul a fost creată astfel încât compartimentarea acțiunilor să fie foarte bine definită.

Componenta de interacțiune cu utilizatorul a aplicației este realizată folosind frameworkul React. Pentru acțiunea de încărcare a imaginii, s-a dezvoltat o pagină HTML (HyperText Markup Language) ce conține o zonă de tragere și plasare a imaginilor, ce poate acționa și ca un buton de încărcare și o căsuță de bifat.

Pentru fiecare activitate care se poate realiza folosind această pagină, s-au definit diferite funcții de gestiune a evenimentelor, după cum urmează:

1. Funcție pentru schimbarea stării căsuței de bifat. Aceasta se activează când câmpul este selectat.
2. Funcții pentru interacțiunea cu zona de tragere și plasare a imaginii. Acestea se activează în momentul în care utilizatorul accesează zona de încărcare, plasează o imagine în acea zonă și/sau părăsește zona de tragere și plasare.

Pentru cea de a doua pagină HTML s-a reutilizat zona deja implementată în prima pagină, dar cu scopul de a afișa rezultatele finale în urma procesării, deci eliminând zona de încărcare și căsuța de bifat. Funcția folosită în cadrul acesteia se ocupă de efectuarea cererii de obținere a rezultatele procesării imaginii imediat după ce aceasta a fost încărcată.

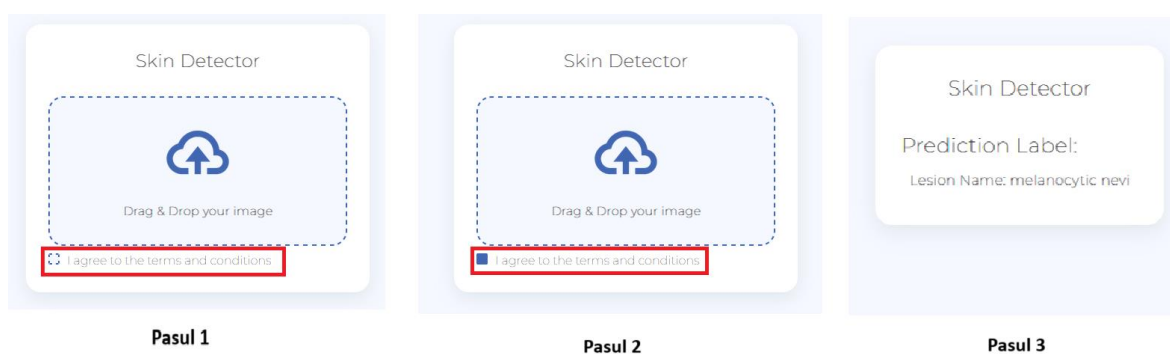
Componenta funcțională a aplicației constă în algoritmul de detecție prezentat anterior și partea de server Flask. Astfel, serverul Flask se ocupă de cererile HTTP în vederea comunicării dintre cele două componente. Cele două cereri de care se ocupă sunt:

1. O cerere de tip POST, care primește o imagine pe care o salvează local în vederea procesării ulterioare a acesteia cu ajutorul algoritmului de detecție. În final, serverul returnează un răspuns cu rezultate obținute.
2. O cerere de tip GET prin care se obțin informații despre imaginea încărcată (nume, rută).

## 7.2 Mod de utilizare a interfeței

Modul de utilizare al aplicației este foarte simplu și este alcătuit din 3 pași ca în figura de jos.

- Primul pas este reprezentat de bifarea căsuței prin care utilizatorul își dă acordul pentru prelucrarea datelor personale.
- Pasul al doilea presupune folosirea chenarului de trage și plasare pentru a încărca imaginea dorită. În final, imaginea este procesată, rezultatul urmând a fi afișat pe ecran, cum e prezentat în pasul trei.



Figură 15. Paginile interfeței cu utilizatorul



## **8. Comparație cu abordările anterioare**

În prezent lucrarea propune o soluție viabilă cu rezultate bune, iar acest lucru a fost posibil datorită abordărilor anterioare. Prima abordare a problemei a avut ca punct de plecare un set de date oferit de cei de la DermNet, care se era alcătuit din 23 de tipuri de patologii dermatologice. Deși aria de acoperire a leziunilor cutanate era mult mai mare, imaginile cu acestea aveau zona de interes acoperită de către un watermark din motive de securitate, ceea ce scade considerabil calitatea datelor de intrare. Astfel, premisa inițială lua în considerare obținerea unor rezultate slabe.

După etapa de prelucrare a imaginilor, rezultatele obținute pentru acest set de date s-au dovedit a fi foarte slabe din punct de vedere a calității și lizibilității trăsăturilor relevante.

Principiul de bază folosit a fost cel de Învățare prin transfer de cunoștințe. Modele utilizate au fost alese ținând cont de limitările generate de resursele de procesare de la momentul respectiv. Rularea se putea realiza doar folosind resursele CPU, ceea ce determina un timp de antrenare foarte mare, de aproximativ 10-12 ore, a fost prima problemă întâmpinată.

Modele folosite au fost InceptionNet și ResNet simplu, ce au fost modificate prin înghețarea primelor straturi și adăugarea unor straturi de convoluție, de agregare și dense, noi.

Rezultatele cele mai bune se observă pe structura folosită în abordarea curentă. S-au adăugat 12 straturi de neuroni, împărțirea acestora fiind identică cu cea actuală. Funcția de activare folosită a fost cea gaussiană. Pentru a reduce valoarea erorii, am aplicat gradientul Batch Gradient și metoda de optimizare RMSprop pentru actualizarea funcției de pierdere.

De asemenea, în ambele cazuri am întâmpinat fenomenul de supraînvățare, care presupune că rețeaua învață să recunoască mult mai bine anumite clase. În plus, modelul nu generalizează bine atunci când folosește datele de validare care includ imagini noi, ce nu fac parte din setul de antrenament. Acest fenomen se întâmplă rapid, încă din prima jumătate a numărului de 10.000 de iterații folosite.

Nu în ultimul rând, modelul actual are o creștere a procentului de acuratețe de aproximativ 35%-45% față de cele două modele prezentate mai sus.

Prin urmare, soluția propusă inițial prin rezultatele furnizate conturează foarte bine importanța folosirii unui set de date potrivit. De asemenea, imaginile de intrare trebuie să prezinte clar și fără să obstrucționeze în vreun fel leziunea cutanată pentru o detecție corectă și pentru a evita fenomenul de supraînvățare a modelului în momentul antrenării.

## **9. Concluzii**

Lucrarea a fost realizată folosind noțiuni foarte cunoscute în domeniul tehnologic actual. Aceasta nu doar prezintă importanța adusă de dezvoltarea unor soluții capabile să funcționeze în baza unor principii inspirate de creierul uman în procesul de învățare și adaptare, dar și ușurința cu care acestea pot fi îmbunătățite.

Cunoștințele matematice din domeniu ingineriei sistemelor se reflectă foarte bine în algoritmul propus de aceasta. Altfel spus, calculul matriceal este foarte bine evidențiat în implementarea straturilor rețelei neuronale folosite.

Un alt aspect care este scos în evidență de accesul la un set de date potrivit problemei abordate. Astfel, dacă datele de intrare sunt compromise sau greu de gestionat, rezultatele vor avea o performanță scăzută, făcând găsirea unei soluții destul de greu de definit.

Lucrarea aduce un sistem de interpretare a datelor medicale digitale ușor de utilizat și cu o rată de succes ridicată. Astfel, s-au exploatat resursele și cercetările anterioare în ceea ce privesc modelele și algoritmi de clasificare și recunoaștere folosind imagini, s-au înțeles mecanismele matematice din spatele acestora și s-a propus o soluție nouă. Noua soluție prezintă o altă metodă de iterare prin pașii de prelucrare și o combinație specială de funcții și operații, ce împreună au condus la o reușită de detectare a tulburărilor dermatologice măsurată într-un procent de acuratețe ce depășește 90% pentru date noi furnizate.

Mai mult, lucrarea aduce un surplus de valoare datorită agregării cunoștințelor de tehnologii web. Aceasta pune la dispoziția utilizatorului o interfață simplă și securizată prin care acesta poate accesa și folosi modelul creat în vederea detecției leziunilor cutanate proprii.

Astfel, lucrarea prezintă importanța progresului tehnologic în domeniul medical, deoarece oferă o metodă accesibilă de conștientizare a modificărilor pielii și a impactului pe care acestea le pot avea dacă nu sunt observate și identificate din timp.

## **10. Considerente pentru o dezvoltare viitoare**

Lucrarea abordează în momentul actual doar șapte tipuri diferite de leziuni cutanate, aspect ce lasă încă nerezolvate multe alte patologii dermatologice. Astfel, o îmbunătățire ce poate fi adusă soluției curente este cea de a aborda un set de date mult mai complex, ce oferă imagini și cu alte boli de piele.

O altă funcționalitate ce poate fi adusă este cea de evaluare a mai multor parametri, nu doar a imaginilor. Altfel spus, creșterea consistenței informațiilor folosite în procesul de antrenare astfel încât să se țină cont și de factori precum: sexul persoanei, vârsta, antecedentele medicale și factorii externi prezenți constant în viața cotidiană a individului.

În plus, o nouă implementare poate aborda modul în care interfața cu utilizatorul operează în acest moment. Spre exemplu, introducerea unor noi funcționalități ce pot permite utilizatorului să indexeze toate testările făcute, să poată găsi informații în legătură cu rezultate furnizate în urma detecției și să găsească clinici de dermatologie pentru a obține un raport medical realizat de către un doctor de specialitate.

Propunerile prezentate reprezintă doar o parte din ideile ce se pot folosi pentru transformarea lucrării, dar în funcție de cerințele utilizatorilor, se pot adapta și implementa noi funcționalități. De asemenea, furnizarea de noi date din partea medicilor pot duce la îmbunătățirea metodelor de recunoaștere și clasificare.

## **Bibliografie**

- [1] H. Yousef, M. Alhajj, S. Sharma, „Anatomy, Skin (Integument), Epidermis”, National Library of Medicine, 14 Noiembrie 2022, <https://www.ncbi.nlm.nih.gov/books/NBK470464/>. [Accesat la 1 August 2023].
- [2] Ferreira Iago Gonçalves, Weber Magda Blessmann, Bonamigo Renan Rangel, „History of dermatology: the study of skin diseases over the centuries”, 2021, <https://doi.org/10.1016/j.abd.2020.09.006>.
- [3] Glatter Kathy, Finkelma Paul, „History of the Plague: An Ancient Pandemic for the Age of COVID-19”, The American journal of medicine, vol. 134, no. 2, pp. 176–181, 2021, <https://doi.org/10.1016/j.amjmed.2020.08.019>. [Accesat la 3 August 2023].
- [4] Stefan Riedel, „Edward Jenner and the history of smallpox and vaccination. Proceedings”, (Baylor University. Medical Center), vol. 18, no. 1, pp. 21–25, 2017, <https://doi.org/10.1080/08998280.2005.11928028>. [Accesat la 6 August 2023].
- [5] „Skin diseases”, World Health Organization, <https://platform.who.int/mortality/themes/theme-details/topics/topic-details/MDB/skin-diseases>. [Accesat la 16 August 2023].
- [6] M. Jafferany and P. Pastolero, „Psychiatric and Psychological Impact of Chronic Skin Disease”, Psychiatrist.com, 26 Aprilie 2018, <https://www.psychiatrist.com/pcc/psychiatry/psychiatric-impact-of-skin-disease/>. [Accesat la 03 Septembrie 2023].
- [7] A. Kalaivani, S. Karpagavalli, „Detection and classification of skin diseases with ensembles of deep learning networks in medical imaging”, International Journal of Health Sciences, vol. 6, no. S1, pp. 13624–13637, 2022, <https://doi.org/10.53730/ijhs.v6nS1.8402>. [Accesat la 6 August 2023].
- [8] Li Yuexiang, Shen Linlin, „Skin Lesion Analysis towards Melanoma Detection Using Deep Learning Network”, Sensors, vol. 18, no. 2, p. 556, Februarie 2018, <https://doi.org/10.3390/s18020556>. [Accesat la 4 August 2023].
- [9] Ertel Wolfgang, „Introduction to artificial intelligence (Second)”, 2017.
- [10] Dwivedi Krit, Sharkey Michael, Condliffe Robin, Uthoff Johanna M., Alabed Samer, Metherall Peter, Lu Haiping, Wild Jim M., Hoffman Eric A., Swift Andrew J., Kiely David G., „Pulmonary Hypertension in Association with Lung Disease: Quantitative CT and Artificial Intelligence to the Rescue? State-of-the-Art Review. Diagnostics”, 2021, [https://www.researchgate.net/publication/350778575\\_Pulmonary\\_Hypertension\\_in\\_Association\\_with\\_Lung\\_Disease\\_Quantitative\\_CT\\_and\\_Artificial\\_Intelligence\\_to\\_the\\_Rescue\\_State-of-the-Art\\_Review](https://www.researchgate.net/publication/350778575_Pulmonary_Hypertension_in_Association_with_Lung_Disease_Quantitative_CT_and_Artificial_Intelligence_to_the_Rescue_State-of-the-Art_Review). [Accesat la 3 August 2023].
- [11] Copeland B., „Artificial Intelligence. Encyclopedia Britannica”, <https://www.britannica.com/technology/artificial-intelligence>.
- [12] Goodfellow Ian, Bengio Yoshua, Courville Aaron, „Deep Learning,” 2016.
- [13] Brownlee J., „A Gentle Introduction to Transfer Learning for Deep Learning”, Machine Learning Mastery, 20 Decembrie 2017, <https://machinelearningmastery.com/transfer-learning-for-deep-learning/>. [Accesat 3 la Septembrie 2023].
- [14] Yamashita Rikiya, Nishio Mizuho, Kinj Gian Do Richard, Togashi Kaori, „Convolutional neural networks: an overview and application in radiology”, Insights Imaging, 03 Martie 2018, <https://insightsimaging.springeropen.com/articles/10.1007/s13244-018-0639-9>. [Accesat la 03 Septembrie 2023].
- [15] Pallets Projects, „Documentație Flask”, Pallets Projects, <https://flask.palletsprojects.com/en/2.3.x/>. [Accesat la 01 Septembrie 2023].

- [16] React, „Documentație React”, <https://react.dev/learn>. [Accesat la 29 August 2023].
- [17] P. Tschandi, „The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions”, H. Dataverse, Ed., 2018, <https://dataverse.harvard.edu/dataset.xhtml?persistentId=doi:10.7910/DVN/DBW86T>.
- [18] Marques Erik, Chen Teris M., „Actinic Keratosis”, 17 August 2023, <https://www.ncbi.nlm.nih.gov/books/NBK557401/>. [Accesat la 29 Iulie 2023].
- [19] Charifa Ahmad, Volner Keith, Oakley Amanda M., „Intraepidermal Carcinoma”, 12 Septembrie 2022, <https://www.ncbi.nlm.nih.gov/books/NBK482474/>. [Accesat la 2 August 2023].
- [20] McDaniel Brianna, Badri Talel, Steele Robert B., „Basal Cell Carcinoma”, 19 Septembrie 2022, <https://www.ncbi.nlm.nih.gov/books/NBK482439/>. [Accesat la 5 August 2023].
- [21] Scott Rebecca and Oakley Amanda, „Benign Keratosis: A Useful Term?”, 2023, <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC10188172/>. [Accesat la 7 August 2023].
- [22] Myers David J., Fillman Eric P., „Dermatofibroma”, 24 Octombrie 2022, <https://www.ncbi.nlm.nih.gov/books/NBK470538/>. [Accesat la 11 August 2023].
- [23] „Melanoma”, Cancer Council, <https://www.cancer.org.au/cancer-information/types-of-cancer/melanoma>. [Accesat la 11 August 2023].
- [24] „Melanocytic Nevi (Moles)”, YaleMedicine, <https://www.yalemedicine.org/conditions/melanocytic-nevi-moles>. [Accesat la 14 August 2023].
- [25] „Skin of color - angioma and other vascular lesions”, dermascopedia, [https://dermoscopedia.org/Benign\\_lesions\\_-\\_angioma\\_and\\_other\\_vascular\\_lesions](https://dermoscopedia.org/Benign_lesions_-_angioma_and_other_vascular_lesions). [Accesat la 13 August 2023].
- [26] „Bilinear interpolation”, X-Engineer, <https://x-engineer.org/bilinear-interpolation/>. [Accesat la 02 Septembrie 2023].
- [27] Vashint Raghav, „When to perform a Feature Scaling?”, 06 Ianuarie 2021, <https://atoti.io/articles/when-to-perform-a-feature-scaling/>. <https://ieeexplore.ieee.org/document/9412193>. [Accesat la 28 August 2023].
- [28] Duta I. C., Liu L., Zhu F. and Shao L., „Improved Residual Networks for Image and Video Recognition”, în 2020 25th International Conference on Pattern Recognition (ICPR), Milan, 2021, <https://ieeexplore.ieee.org/document/9412193>.
- [29] Banjara Babina, „Deep Residual Learning for Image Recognition (ResNet Explained)”, 07 Februarie 2023, <https://www.analyticsvidhya.com/blog/2023/02/deep-residual-learning-for-image-recognition-resnet-explained/>. [Accesat la 27 August 2023].
- [30] Deng Jia, Dong Wei, Socher Richard, Li Li-Jia, Li Kai, Fei-Fei Li, „ImageNet: A large-scale hierarchical image database”, în 2009 IEEE Conference on Computer Vision and Pattern Recognition, Miami, 2009, <https://ieeexplore.ieee.org/document/5206848>.
- [31] Rahimzadeh Mohammad, Attar Abolfazl, „A modified deep convolutional neural network for detecting COVID-19 and pneumonia from chest X-ray images based on the concatenation of Xception and ResNet50V2”, 2020, <https://pubmed.ncbi.nlm.nih.gov/32501424/>. [Accesat la 29 August 2023].
- [32] Naranjo-Torres José, Mora Marco, Hernández-García Ruber, Barrientos Ricardo J., Fredes Claudio, Valenzuela Andres, „A review of Convolutional Neural Network Applied to Fruit Image Processing”, 16 Aprilie 2020, <https://www.mdpi.com/2076-3417/10/10/3443>. [Accesat la 29 August 2023].

- [33] Thakkar Vignesh, Tewary Suman, Chakraborty Chandan, „Batch Normalization in Convolutional Neural Networks — A comparative study with CIFAR-10 data”, în 2018 Fifth International Conference on Emerging Applications of Information Technology (EAIT), Kolkata, 2018, <https://ieeexplore.ieee.org/document/8470438>.
- [34] Sharma Simone, Sharma Siddharth, Athaiya Anidhya, „Activation Functions in Neural Networks”, International Journal of Engineering Applied Sciences and Technology, vol. 4, nr. 12, pp. 310-316, 2020, <https://www.ijeast.com/papers/310-316,Tesma412,IJEAST.pdf>.
- [35] Hendrycks Dan, Gimpel Kevin, „Gaussian Error Linear Units (GELUs)”, 27 Iunie 2016, <https://arxiv.org/abs/1606.08415>. [Accesat la 01 Septembrie 2023].
- [36] Tagarelli A., Tong H., „Computational Data and Social Networks”, în 8th International Conference, CSoNet, Ho Chi Minh City, 2019.
- [37] Kuman Avinash, Sarkar Sobhangi, Pradhan Chittaranjan, „Malaria Disease Detection Using CNN Technique with SGD, RMSprop and ADAM Optimizers”, 2020.
- [38] Ketkar N., „Introduction to Keras”, 5 Octombrie 2017.